

Redes Bayesianas Gaussianas: Un estudio de la influencia de los contaminantes del aire en la salud de la población mexicana

Romina Nájera Fuentes - A01424411

Humberto Mondragón García - A01711912

Juan Braulio Olivares Rodríguez - A01706880

Edgar Andrey Balvaneda - A01644770

Análisis de métodos de razonamiento e incertidumbre

7 de Septiembre del 2025

Abstract

Introducción

La contaminación ambiental se ha convertido en una problemática crítica para la salud pública a nivel mundial. Según la Organización Mundial de la Salud, 9 de cada 10 personas respiran aire con altos niveles de contaminantes, y 4.2 millones de personas mueren al año a causa de la contaminación del aire del exterior. [9]

En México, en las zonas metropolitanas, como la Ciudad de México, Monterrey y Guadalajara, se reportan concentraciones elevadas de contaminantes provenientes del intenso tráfico vehicular, sus altas densidades poblacionales y la actividad industrial con pocas o nulas restricciones en la liberación de contaminantes en el ambiente. Si bien esta mezcla de contaminantes es compleja, ciertos de ellos son especialmente preocupantes por su impacto en la salud pública. Los datos de la SEMARNAT nos proveen de los siguientes contaminantes:

El material particulado (PM_{10} y $PM_{2.5}$) constituye uno de los contaminantes atmosféricos más nocivos para la salud. Proviene principalmente de procesos de combustión como los de vehículos o actividades industriales, es culpable de agravamiento de los síntomas del asma, deterioro de la función pulmonar y aumento del riesgo de cáncer de pulmón, garganta o laringe.[1]

El dióxido de azufre (SO_2) es un gas que se produce principalmente por la quema de combustibles fósiles como el carbón y el petróleo. Su inhalación provoca irritación de las vías respiratorias y desencadena reacciones inflamatorias locales y sistémicas. [7]

El monóxido de carbono (CO), por su parte, es un gas inodoro y altamente tóxico que se produce principalmente por la combustión incompleta de gasolina, madera, carbón o gas. Su mecanismo de toxicidad se debe a su alta afinidad con la hemoglobina, lo que desplaza al oxígeno y disminuye la capacidad de transporte de este en la sangre. [4]

Los óxidos de nitrógeno (NOx), que incluyen principalmente el dióxido de nitrógeno (NO_2) y el óxido nítrico (NO), se generan a partir de procesos de combustión como en vehículos motorizados, plantas eléctricas e industrias. Estos gases son potentes irritantes de las vías respiratorias, provocan inflamación bronquial y reducen la función pulmonar. [2]

Por último, los compuestos orgánicos volátiles (COV) y el amoníaco (NH_3), aunque menos estudiados en comparación con los contaminantes anteriores, también tienen efectos relevantes en la calidad del aire y la salud. Se han vinculado con irritación ocular y respiratoria, así como con procesos de estrés oxidativo. [3] Los COV provienen de solventes, combustibles, pinturas y procesos industriales, contribuyen junto con los NOx a la formación de ozono troposférico. [8]

Por la ya mencionada complejidad de los contaminantes, resulta necesario estudiar no solo su presencia ambiental, sino también sus repercusiones biológicas medibles en la población.

El presente trabajo tiene como objetivo principal implementar un modelo probabilístico

que permita identificar en qué medida estos contaminantes influyen en la salud de la población mexicana, analizando sus biomarcadores. Comprender la magnitud de este impacto, el origen de los contaminantes, y los componentes biológicos afectados es fundamental para el diseño de políticas públicas efectivas y estrategias de prevención.

Para ello utilizamos los datos de muestras biológicas de la Encuesta Nacional de Salud y Nutrición (ENSANUT) 2022, y registros de contaminantes atmosféricos provenientes de la SEMARNAT.

Existen diversos enfoques estocásticos que podemos utilizar para modelar la influencia de los contaminantes en los biomarcadores. Entre ellos se encuentran métodos como la regresión, que permite evaluar asociaciones entre variables, los procesos de Poisson, que modelan conteos de eventos discretos, y las simulaciones Monte Carlo, que permiten explorar el comportamiento de modelos complejos. Sin embargo, estas aproximaciones frecuentemente se centran en relaciones simples entre variables o en estructuras lineales, lo que limita su capacidad de capturar la red de dependencias entre las variables de este estudio. Frente a ello, las redes bayesianas gaussianas ofrecen una alternativa más flexible representando las relaciones de dependencia en forma de un grafo acíclico dirigido y modelar la incertidumbre mediante distribuciones gaussianas.

Metodología

Una red bayesiana es definida como un grafo acíclico dirigido, conocido como DAG, $D = (V, E)$, en donde $V = \{X_1, X_2, \dots, X_n\}$ representa a las variables del problema, y E representa las relaciones de dependencia entre las variables. Asimismo, se cuenta con P , el conjunto de distribuciones de probabilidad asociadas a cada nodo.

Se utilizará una red bayesiana de tipo gaussiana, la cual es utilizada para modelar variables aleatorias continuas que siguen una distribución normal. En este caso, la distribución conjunta de las variables del problema es normal multivariada; es decir, sigue una distribución $N(\mu, \Sigma)$, siendo μ el vector de medias y Σ la matriz de covarianzas. [6]

En la versión gaussiana de la red bayesiana, los nodos raíz, o nodos sin padres, siguen marginalmente una distribución univariada normal. Los demás nodos siguen de manera marginal una distribución condicionada normal, con una media que se representa a través de un modelo lineal respecto a las medias de los padres, y con una varianza propia [10].

Entre las variables presentadas en la ENSANUT, se encuentra información sociodemográfica de las personas encuestadas, como el sexo, la edad, la zona de residencia, el acceso a servicios de salud pública, entre otros. Sin embargo, de estos solamente se tomará en cuenta la edad, que es una variable que se puede considerar continua, y el lugar en el que se reside, para asignar los niveles de contaminantes a los que los encuestados se exponen de manera constante.

Además de la información sociodemográfica, la encuesta también contiene información relacionada con biomarcadores. Estos incluyen los niveles de ácido úrico, albúmina, colesterol HDL y LDL, colesterol total, creatinina, glucosa, insulina, proteína C reactiva, triglicéridos, hemoglobina glucosilada, ferritina, folato, homocisteína, receptor de transferrina, vitamina B12 y vitamina D de los encuestados. Si bien se cuenta con más información, estas variables son las que son continuas, condición necesaria en las redes bayesianas gaussianas, por lo que el impacto en la salud se determinará solamente con estas variables.

Con la información de la SEMARNAT, como se mencionó previamente en la introducción, se utilizarán los niveles de los contaminantes SO_2 , CO , COV , NOx , PM_{10} y $PM_{2.5}$ medidos en los municipios de cada estado del país. Los contaminantes se dividen en diferentes tipos de fuentes causantes, que son las fuentes fijas, de área, móviles carreteros, móviles que no circulan por carretera y naturales. Por observación del Dr. Ernesto Reyes Villegas, experto en calidad del aire, estas fuentes son complementarias, por lo que la suma de los contaminantes en cada fuente es equivalente a la contaminación total en dicho municipio. Sin embargo, en vista de que no todos los municipios presentan información completa en las fuentes fijas y las fuentes naturales, se considerará que el nivel de contaminación a la que se somete una persona que reside en un municipio, es igual a la suma de la contaminación de fuentes de área, de móviles carreteros y de móviles que no circulan por carretera para cada contaminante por municipio.

Las variables seleccionadas son exclusivamente continuas, con el propósito de utilizar la red bayesiana gaussiana. Agregar una variable categórica, como lo podría ser el sexo de la persona encuestada, representaría utilizar un modelo distinto al aquí presentado. Una manera de realizarlo es a través de la discretización de las variables continuas. Sin embargo, para una mayor precisión, la discretización se tendría que llevar con múltiples categorías para cada variable, lo cual incrementa la complejidad del modelo y su tiempo de cómputo. [5]

Otra manera de realizar el modelo con la combinación de variables discretas y continuas es a través de una red bayesiana mixta. En esta, los nodos discretos siguen una distribución multinomial, y sus nodos padres pueden ser solamente otras variables discretas. En cambio, los nodos continuos simplemente siguen una distribución normal, cuando ninguno de sus nodos padre son discretos; y siguen un conjunto de distribuciones normales, cada una para cada posible combinación de las variables de las que dependen, en caso de tener alguna variable discreta como nodos padre. [10]

Utilizando estas variables, se consultará a especialistas en las áreas de medicina y de bioquímica, quienes apoyarán en la realización de la red bayesiana gaussiana, seleccionando las variables de interés, y proponiendo las relaciones que consideren relevantes.

Con ello, se generarán 3 DAGs, las cuales serán ajustadas a los datos para ser posteriormente comparadas entre sí a través del Criterio de Información Bayesiano (BIC), el cual considera la verosimilitud y la complejidad de cada modelo para asignar un puntaje que se busca maximizar [10], y del Criterio de Información Akaike (AIC), el cual considera los

mismos parámetros que el BIC, pero penaliza en menor escala a la complejidad del modelo.

Después de seleccionar un modelo óptimo en base al puntaje BIC, se formarán 3 preguntas a resolver con dicha red bayesiana, las cuales se propondrán con el apoyo de los especialistas contactados para la propuesta de las redes.

Aplicación

Conclusión

Referencias

- [1] Airly. *What is PM2.5 and PM10? Info about particulate matter (particle pollution)*. Consultado: 06-09-2025. s.f. URL: <https://airly.org/en/what-is-pm10-and-what-is-pm2-5/>.
- [2] ATSDR. *Resúmenes de Salud Pública – Amoníaco (Ammonia)*. Consultado: 06-09-2025. 2016. URL: https://www.atsdr.cdc.gov/es/phs/es_phs126.html.
- [3] ATSDR. *ToxFAQs™ – Óxidos de nitrógeno (monóxido de nitrógeno, dióxido de nitrógeno, etc.) (Nitrogen Oxides)*. Consultado: 06-09-2025. 2026. URL: https://www.atsdr.cdc.gov/es/toxfaqs/es_tfacts175.html.
- [4] Mayo Clinic. *Intoxicación con monóxido de carbono*. Consultado: 06-09-2025. 2025. URL: <https://www.mayoclinic.org/es/diseases-conditions/carbon-monoxide/symptoms-causes/syc-20370642>.
- [5] R.G. Cowell et al. “Probabilistic Networks and Expert Systems”. In: vol. 43. Jan. 2001, pp. 125–126.
- [6] Rosario Susi García. “Análisis de sensibilidad en redes bayesianas gaussianas”. PhD thesis. Madrid: Universidad Complutense de Madrid, 2007.
- [7] IVHHN. *Dióxido de azufre (SO₂)*. Consultado: 06-09-2025. 2003. URL: <https://www.ivhnn.org/es/guidelines/guia-sobre-gases-volcanicos/dioxido-de-azufre>.
- [8] Agencia de Protección Ambiental de los Estados Unidos. *El impacto de los compuestos orgánicos volátiles en la calidad del aire interior*. Consultado: 06-09-2025. 2025. URL: <https://espanol.epa.gov/cai/el-impacto-de-los-compuestos-organicos-volatiles-en-la-calidad-del-aire-interior>.
- [9] Organización Mundial de la Salud. *Nueve de cada diez personas de todo el mundo respiran aire contaminado*. Consultado: 06-09-2025. 2018. URL: <https://www.who.int/es/news/item/02-05-2018-9-out-of-10-people-worldwide-breathe-polluted-air-but-more-countries-are-taking-action>.
- [10] Marco Scutari and Jean-Baptiste Denis. *Bayesian Networks: With Examples in R*. 2nd ed. Texts in Statistical Science. CRC Press, 2021. ISBN: 978-0-367-36651-3.